

HIVE NOTES



[More Detailed Info](#)

L. Brunetti

È un software di **datawarehouse** che facilita lettura, scrittura e gestione di ampi dataset in **DFS** usando una sintassi **SQL**


Hive è costruito su **hadoop** e fornisce le seguenti features:

- Tools per accedere ai dati via **SQL** per ETL, reporting e analisi
- Un meccanismo per **imporre una struttura** ad una **varieta di data format**
- Accesso ai dati diretti su **HDFS** o **NBose**
- Esecuzione di query tramite **SPARK, MAP-REDUCE** o **TBZ**
- Linguaggio **procedurale** con **HQL-SQL**
- Sub second query retrieval

Hive fornisce **SQL** fin al 2016. Può anche essere esteso tramite **UDF, UDAF e UDTF**. Legge vari formati quali **Parquet, orc** ecc... Hive **non è** ideale per **OLTP** ma **si** per **OLAP**. Massimizza scalabilità, performance, estensibilità, fault tolerance con il suo input format. Include:

- **HCATALOG**: una tabella di storage management per Hadoop che permette all'utente di leggere e scrivere più facilmente.
- **WEBHCAT**: servizio per eseguire **PyHive**, **Pig** o **Hive** jobs.

Scopo primario di Hive dunque è quello di dare una struttura ad un insieme di dati non strutturati per poter poi usare **SQL** su di essi, **senza dover conoscere SPARK, MAP-REDUCE** o linguaggi di programmazione.



TIPI DI TABELLE - MANAGED

Sia i **dati** che gli **schema** sono gestiti da **Hive**. I dati sono in una cartella in un file su **HDFS**. La location può essere configurata dall'utente all'installazione di Hive, quella di default è **/user/hive/warehouse**.

Se una tabella managed viene eliminata **Hive cancella schema e dati**.

TIPI DI TABELLE - EXTERNAL

Sono tabelle in cui **solo lo schema è gestito da Hive**, mentre i dati restano indipendenti

Managed vs. External Table - What's the Difference?

Managed Table	External Table
Hive assumes that it owns the data for managed tables. If a managed table or partition is dropped, the data and metadata associated with that table or partition are deleted. For Managed tables, Hive stores data into its warehouse directory. Managed table provides ACID/transactional action support. Statements: ARCHIVE, UNARCHIVE, TRUNCATE, MERGE, CONCATENATE supported. Query Result Caching supported (saves the results of an executed Hive query for reuse).	For external tables, Hive assumes that it does not manage the data. Dropping the table does not delete the data, although the metadata for the table will be deleted. For External Tables, Hive stores the data in the LOCATION specified during creation of the table (generally not in warehouse directory). External Table does not provide ACID/transactional action support. Not supported.

Syntax to Create Managed Table

```
CREATE TABLE IF NOT EXISTS stocks (exchange STRING,
symbol STRING,
price_open FLOAT,
price_high FLOAT,
price_low FLOAT,
price_adj_close FLOAT)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ',';
```

Syntax to Create External Table

```
CREATE EXTERNAL TABLE IF NOT EXISTS stocks (exchange STRING,
symbol STRING,
price_open FLOAT,
price_high FLOAT,
price_low FLOAT,
price_adj_close FLOAT)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
LOCATION '/data/stocks';
```